



UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

INTELIGENCIA ARTIFICIAL AVANZADA

Grupo C

Entrega N° 2

INTEGRANTES DEL GRUPO

Apellido y Nombres	E-Mail	Porcentaje de Aporte
Martinez, Guido Julián	guidojmartinez@frba.utn.edu.ar	16,6%
Duarte, Gonzalo	goduarte@frba.utn.edu.ar	16,6%
Gliozzo, Tomás Esteban	tgliozzo@frba.utn.edu.ar	16,6%
Lazzati, Camila	clazzati@frba.utn.edu.ar	16,6%
Ibire, Fidel	fibire@frba.utn.edu.ar	16,6%
Ascorti, Federico	fascorti@frba.utn.edu.ar	16,6%

Fecha de Presentación

05/09/26

Evaluación General de la Entrega:

Resumen. Se desarrolló una prueba de concepto para la identificación automática de ocho especies vegetales mediante Redes Neuronales Convolucionales (CNN) y su posterior clasificación regional como Nativa o Exótica para la Provincia de Buenos Aires. La Entrega 2 se estructuró como una secuencia de tres experimentos controlados sobre el mismo dataset y la misma partición train/validation/test. El primer experimento estableció una línea base con una CNN que utiliza Flatten; el segundo reemplazó dicha etapa por GlobalAveragePooling2D, reduciendo drásticamente la cantidad de parámetros y mejorando la capacidad de generalización; y el tercero mantuvo esta arquitectura e incorporó Data Augmentation para evaluar su impacto sobre el sobreajuste. Los resultados mostraron que el segundo experimento obtuvo el mejor desempeño global, alcanzando una Test Accuracy de 61,12 % y un Macro-F1 de 59,75 % a nivel de especie, por lo que fue seleccionado como prototipo final de esta entrega. El tercer experimento redujo la brecha entre entrenamiento y validación, pero no superó al segundo sobre el conjunto de prueba, evidenciando que la regularización mediante Data Augmentation no implica necesariamente una mejora en la capacidad de generalización.

1. Introducción

La flora de la Provincia de Buenos Aires presenta una amplia variedad de especies nativas y exóticas. La identificación visual de una especie no siempre resulta sencilla para personas no especializadas, especialmente cuando las fotografías presentan variaciones de iluminación, escala, estación del año, etapa de crecimiento, ángulo de captura, fondo y parte de la planta observada.

El objetivo del trabajo es desarrollar un sistema inteligente capaz de identificar, dentro de un conjunto acotado de especies previamente seleccionadas, la especie vegetal presente en una fotografía. Una vez identificada, el sistema consulta un catálogo botánico regional para informar si se trata de una especie Nativa o Exótica en la Provincia de Buenos Aires.

El alcance de esta entrega se limita explícitamente a las categorías Nativa y Exótica. La condición regional no se infiere directamente a partir de los píxeles: el componente de inteligencia artificial identifica la especie y un segundo componente consulta conocimiento botánico estructurado. Esta separación evita asociar una propiedad geográfica a características visuales que, por sí solas, no determinan el origen regional de una especie.

La Entrega 2 se plantea como una prueba de concepto experimental. Además de implementar el flujo completo, se comparan distintas configuraciones de una CNN entrenada desde cero con el objetivo de analizar generalización, complejidad y principales fuentes de error, reservando técnicas de mayor complejidad como Transfer Learning y Object Detection para una evolución posterior.

2. Materiales Disponibles

Fuente principal de imágenes utilizada:

- iNaturalist Open Data / API iNaturalist: utilizada para construir el dataset experimental y conservar trazabilidad por observación, licencia y URL de origen.

Fuentes botánicas y complementarias:

- Flora Argentina: utilizada como referencia para la condición regional de las especies.
- Pl@ntNet-300K: evaluada como fuente complementaria de imágenes, pero no utilizada para construir el dataset de esta versión.
- Lista oficial argentina de especies exóticas: utilizada únicamente como referencia complementaria para validar información botánica; no introduce una tercera categoría de salida en el alcance del sistema.

2.1. Especies seleccionadas y catálogo regional

Nombre científico	Nombre común	Condición en PBA
Erythrina crista-galli	Ceibo	Nativa
Passiflora caerulea	Mburucuyá	Nativa
Cortaderia selloana	Cortadera	Nativa
Phytolacca dioica	Ombú	Nativa
Ligustrum lucidum	Ligustro	Exótica
Gleditsia triacanthos	Acacia negra	Exótica
Melia azedarach	Paraíso	Exótica
Iris pseudacorus	Lirio amarillo	Exótica

La tabla constituye el catálogo utilizado por la segunda etapa del sistema.

2.2. Construcción, balanceo y partición del dataset

Se recopilaron 3.200 imágenes, 400 por especie. Para reducir el riesgo de fuga de información se utilizó una única fotografía por observación de iNaturalist. Se verificó la integridad de los archivos y se descartaron imágenes no válidas o corruptas. Posteriormente se balanceó el dataset y se realizó una partición estratificada 60/15/25.

Especie	Train	Validación	Test	Total
Cortaderia selloana	240	60	100	400
Erythrina crista-galli	240	60	100	400
Gleditsia triacanthos	240	60	100	400
Iris pseudacorus	240	60	100	400
Ligustrum lucidum	240	60	100	400
Melia azedarach	240	60	100	400
Passiflora caerulea	240	60	100	400
Phytolacca dioica	240	60	100	400
TOTAL	1.920	480	800	3.200

Las imágenes provienen de observaciones reales y presentan elevada variabilidad en iluminación, encuadre, escala, entorno y parte de la planta fotografiada. No se realizó una curación manual exhaustiva de todas las fotografías; por lo tanto, la presencia de fondos complejos o elementos visuales poco discriminantes constituye una limitación del conjunto utilizado. Esta característica es relevante para interpretar los resultados y motiva parte de la experimentación realizada.

3. Solución Propuesta

La solución consiste en un clasificador multiclase basado en CNN que recibe una imagen RGB y predice una de ocho especies. Posteriormente, la especie estimada se utiliza como clave para consultar el catálogo regional y devolver la condición Nativa o Exótica.

Etapa	Entrada	Proceso	Salida
1. Identificación visual	Fotografía RGB	CNN supervisada de 8 clases	Especie + probabilidades Softmax
2. Clasificación regional	Especie estimada	Consulta al catálogo botánico	Nativa / Exótica

3.1. Tecnologías y herramientas

- Python: implementación general del prototipo.
- Google Colab: entorno de desarrollo y ejecución.
- TensorFlow/Keras: definición, entrenamiento e inferencia de las CNN.
- Pandas: organización de manifests, auditorías y resultados.
- Scikit-learn: métricas, classification report y matrices de confusión.
- Pillow/Matplotlib: procesamiento y visualización de imágenes.
- Google Drive: almacenamiento persistente de dataset, modelos y artefactos de cada corrida.

3.2. Diseño experimental

Esta entrega se organiza en tres experimentos consecutivos. Para preservar comparabilidad se mantiene el mismo dataset balanceado, las mismas ocho clases, el mismo seed (42), el mismo esquema de partición 60/15/25, batch size 32, optimizador Adam, categorical cross-entropy y Dropout 0,30. Las diferencias se introducen de forma controlada para poder asociar los cambios observados a decisiones concretas de arquitectura o entrenamiento.

Característica	Experimento 1	Experimento 2	Experimento 3
Rol	Línea base	Arquitectura simplificada	Generalización con augmentation
Resolución	256×256	224×224	224×224
Conv2D	32 / 64 / 128	32 / 64 / 128	32 / 64 / 128
Reducción final	Flatten	GlobalAveragePooling2D	GlobalAveragePooling2D
Dense	128	128	128
Dropout	0,30	0,30	0,30
Data Augmentation	No	No	Sí
Early Stopping	Sí	Sí	Sí
Learning rate	0,001	0,001	0,001
Épocas máximas	50	200	50

3.3. Arquitecturas evaluadas

3.3.1. Experimento 1 - CNN con Flatten

La línea base utiliza tres bloques Conv2D + MaxPooling2D. Luego aplica Flatten sobre los mapas de características, una capa Dense de 128 neuronas, Dropout 0,30 y una salida Softmax de ocho neuronas. Con entrada 256×256, la combinación Flatten + Dense genera 16.871.624 parámetros entrenables, concentrando gran parte de la capacidad del modelo en el clasificador final.

3.3.2. Experimento 2 - CNN con GlobalAveragePooling2D

En el segundo experimento se mantiene la extracción convolucional, pero se reemplaza Flatten por GlobalAveragePooling2D y se utiliza una resolución de 224×224. Esta operación resume cada mapa de características mediante su promedio espacial y reduce el modelo a

110.792 parámetros entrenables. El objetivo es disminuir la capacidad de memorización y favorecer una representación más generalizable.

3.3.3. Experimento 3 - CNN con GlobalAveragePooling2D + Data Augmentation

El tercer experimento conserva la arquitectura y resolución del Experimento 2 e incorpora Data Augmentation únicamente durante el entrenamiento. Las transformaciones aplicadas son RandomFlip horizontal, RandomRotation(0,08), RandomZoom(0,10) y RandomContrast(0,10). El dataset original no se duplica físicamente: Keras genera variaciones aleatorias durante model.fit y no aplica estas transformaciones en validación ni prueba.

4. Desarrollo

4.1. Flujo de implementación y trazabilidad

El notebook automatiza la consulta y descarga de imágenes, la creación de un manifest con metadatos, el balanceo, la partición estratificada, la creación de datasets TensorFlow, el entrenamiento, la evaluación y el guardado de artefactos. Cada corrida se guarda en una carpeta independiente dentro de artifacts_entrega2, incluyendo modelo, métricas JSON, historial de entrenamiento, resultados de test y resumen de arquitectura.

- **Dataset:** 3.200 imágenes balanceadas (400 por especie).
- **Train:** 1.920 imágenes; validación: 480; test: 800.
- Auditoría por especie y split generada desde el notebook.
- Una sola imagen por observation_id para reducir duplicación entre registros.
- Test mantenido con 100 imágenes por especie.

4.2. Entrenamiento y criterio de evaluación


Los modelos se entrenan con Adam y categorical_crossentropy. Early Stopping monitorea val_loss y restaura los pesos de la mejor época. Durante la experimentación se analizan las curvas de entrenamiento y validación para detectar sobreajuste. Las métricas finales se calculan sobre el conjunto de test una vez completado el entrenamiento de cada configuración.

Para interpretar la comparación se consideran Test Accuracy, Test Loss y Macro-F1 a nivel especie, además de Accuracy y Macro-F1 de la condición regional derivada. El Macro-F1 resulta especialmente útil porque asigna el mismo peso a cada una de las ocho clases.

4.3. Implementación del Data Augmentation en el Experimento 3

El tercer experimento incorpora transformaciones leves y compatibles con el dominio. El objetivo no es alterar la identidad botánica de la planta, sino exponer al modelo a variaciones plausibles de orientación, escala y contraste para reducir la memorización de detalles específicos de las fotografías de entrenamiento.

Transformación	Parámetro	Objetivo
RandomFlip	horizontal	Reducir dependencia de orientación lateral
RandomRotation	0,08	Introducir rotaciones moderadas
RandomZoom	0,10	Variar escala y distancia aparente
RandomContrast	0,10	Simular variaciones leves de contraste



4.4. Proceso de inferencia

La función de inferencia carga una imagen nueva, la convierte a RGB, adapta su resolución, ejecuta el modelo y obtiene el vector Softmax de ocho clases. La especie con mayor probabilidad se utiliza como predicción principal y luego se consulta el catálogo regional. Para evitar interpretar Softmax como una certeza calibrada, el informe utiliza el término “probabilidad Softmax” en lugar de “nivel de confianza”.

El notebook puede mostrar además el Top-3 de especies con mayor probabilidad, permitiendo observar si la predicción principal domina claramente o si existe ambigüedad entre varias clases.

5. Resultados

Los resultados se presentan por experimento. Los tres experimentos se evaluaron sobre el mismo conjunto de pruebas de 800 imágenes, manteniendo las ocho especies y la misma partición del dataset. El Experimento 1 funciona como línea base; el Experimento 2 evalúa el impacto de simplificar la arquitectura mediante GlobalAveragePooling2D; y el Experimento 3 analiza el efecto de incorporar Data Augmentation sobre la arquitectura del Experimento 2.

5.1. Experimento 1 - Línea base con Flatten

Métrica	Resultado
Parámetros entrenables	16.871.624
Test Accuracy especie	38,13 %
Macro-F1 especie	37,55 %
Test Loss	1,6168
Accuracy Nativa/Exótica	70,88 %
Macro-F1 Nativa/Exótica	70,36 %
Mejor época según val_loss	4

El Experimento 1 muestra sobreajuste marcado. La accuracy de entrenamiento aumenta rápidamente hasta valores cercanos al 97 %, mientras que la validación permanece alrededor del 35-40 % y val_loss crece de forma sostenida luego de las primeras épocas. Early Stopping restaura los pesos de la época 4.




Figura 1. Evolución de accuracy y loss en el Experimento 1.




Figura 2. Matriz de confusión por especie - Experimento 1.

5.2. Experimento 2 - GlobalAveragePooling2D

Métrica	Resultado E2	Variación vs Exp. 1
Parámetros entrenables	110.792	- 99,34%
Test Accuracy especie	61,12 %	+ 22,99 pp
Macro-F1 especie	59,75 %	+ 22,20 pp
Test Loss	1,1596	- 0,4572 (-28,3%)
Accuracy Nativa/Exótica	76,12 %	+ 5,24 pp
Macro-F1 Nativa/Exótica	76,05 %	+ 5,69 pp
Mejor época según val_loss	94	+ 90 épocas

La simplificación arquitectónica produce una mejora significativa. El modelo utiliza aproximadamente 0,66 % de los parámetros de la primera red y, aun así, incrementa la accuracy de especie en 23 puntos porcentuales.




Figura 3. Evolución de accuracy y loss en el Experimento 2.




Figura 4. Matriz de confusión por especie - Experimento 2.

5.3. Experimento 3 - GlobalAveragePooling2D + Data Augmentation

El tercer experimento mantiene la arquitectura del Experimento 2 y agrega transformaciones aleatorias durante el entrenamiento. El objetivo fue evaluar si aumentar la diversidad efectiva de los ejemplos permitía mejorar la generalización sin modificar el conjunto de imágenes original ni el conjunto de pruebas.

Métrica	Resultado Exp. 3	Variación vs Exp. 2
Parámetros entrenables	110.792	-
Test Accuracy especie	44,50 %	- 16,62 pp
Macro-F1 especie	42,56 %	- 17,19 pp
Test Loss	1,5409	+ 0,3813 (+32,9%)
Accuracy Nativa/Exótica	71,38 %	- 4,74 pp
Macro-F1 Nativa/Exótica	71,32 %	- 4,73 pp
Mejor época según val_loss	35	- 59 épocas




Figura 6. Evolución de accuracy y loss en el Experimento 3.




Figura 7. Matriz de confusión por especie - Experimento 3.

El Experimento 3 redujo de forma visible la brecha entre entrenamiento y validación, pero no mejoró el desempeño final sobre datos no vistos. Early Stopping restauró los pesos de la época 35, donde val_loss alcanzó 1,5775. La mejor val_accuracy observada durante el entrenamiento fue 45,21 % en la época 43, pero esa época no presentó el menor val_loss. En test, la accuracy de especie fue 44,50 % y el Macro-F1 42,56 %, inferiores al Experimento 2. Esto indica que las transformaciones seleccionadas actuaron como

regularización, pero en esta configuración dificultaron el aprendizaje de rasgos discriminantes necesarios para separar algunas especies.

5.4. Comparación por especie entre los tres experimentos

Especie	F1 Exp. 1	F1 Exp. 2	F1 Exp. 3
Cortaderia selloana	64,65 %	83,48 %	70,49 %
Erythrina crista-galli	71,91 %	73,36 %	77,19 %
Gleditsia triacanthos	20,63 %	52,03 %	18,92 %
Iris pseudacorus	43,87 %	82,16 %	57,29 %
Ligustrum lucidum	8,89 %	50,78 %	35,22 %
Melia azedarach	25,90 %	19,84 %	1,87 %
Passiflora caerulea	42,53 %	62,15 %	47,48 %
Phytolacca dioica	22,07 %	54,18 %	32,03 %

La mejora del Experimento 2 frente a la línea base no se distribuye de forma uniforme. Ligustrum lucidum, Iris pseudacorus, Gleditsia triacanthos y Phytolacca dioica mejoran de manera marcada. Al incorporar Data Augmentation en el Experimento 3, la mayoría de las clases pierde F1 respecto del Experimento 2; Erythrina crista-galli es la única que mejora levemente. El deterioro es especialmente fuerte en Melia azedarach, Gleditsia triacanthos e Iris pseudacorus. Por este motivo, el Experimento 2 continúa siendo la mejor configuración de esta entrega.

5.5. Comparación global de los tres experimentos

La comparación muestra que la principal mejora de esta entrega proviene de la simplificación arquitectónica del Experimento 2. El Experimento 3 aporta una regularización adicional, pero sus métricas de test retroceden respecto de la configuración sin augmentation. En consecuencia, la hipótesis de que las transformaciones seleccionadas mejorarían automáticamente la generalización no se confirma en esta corrida.

Métrica	Exp. 1 Flatten	Exp. 2 GAP	Exp. 3 GAP + Augmentation
Test Accuracy especie	38,13 %	61,12 %	44,50 %
Macro-F1 especie	37,55 %	59,75 %	42,56 %
Test Loss	1,6168	1,1596	1,5409
Accuracy Nativa/Exótica	70,88 %	76,12 %	71,38 %
Macro-F1 Nativa/Exótica	70,36 %	76,05 %	71,32 %
Parámetros entrenables	16.871.624	110.792	110.792

Prototipo seleccionado: Experimento 2 - CNN con GlobalAveragePooling2D.

Es la configuración con mejor Test Accuracy (61.12 %), mejor Macro-F1 de especie (59,75 %), menor Test Loss (1,1596) y mejores métricas Nativa/Exótica (76.12 % de accuracy y 76,05% de Macro-F1). El Experimento 3 redujo el sobreajuste, pero no superó al Experimento 2 en generalización sobre el conjunto de pruebas.

5.6. Evaluación de la condición regional Nativa/Exótica

La evaluación regional se deriva de la especie predicha. Por este motivo, una confusión entre dos especies de la misma condición es un error de especie pero un acierto a nivel

Nativa/Exótica. Esto explica que las métricas de condición sean superiores a las de identificación exacta.

En el Experimento 2, la accuracy regional alcanza 76,12 % y el Macro-F1 76,05 %, frente a 70,88 % y 70,36 % respectivamente en el Experimento 1. El Experimento 3 alcanza 71,38 % de accuracy regional y 71,32 % de Macro-F1. Aunque el Data Augmentation mantiene un rendimiento regional ligeramente superior al Experimento 1, no supera al Experimento 2.




Figura 8. Matriz de confusión Nativa/Exótica - Experimento 2.




Figura 9. Matriz de confusión Nativa/Exótica - Experimento 3.

5.7. Casos representativos y errores

El análisis de errores debe concentrarse en el modelo seleccionado. Conviene incluir ejemplos correctos e incorrectos de todas las especies, priorizando errores con alta probabilidad Softmax y pares de clases que se confunden sistemáticamente. La evidencia de que algunas predicciones incorrectas reciben probabilidades elevadas confirma que Softmax no debe interpretarse como una certeza calibrada.

Los ejemplos de los experimentos 1 y 2 muestran además que una fotografía puede contener fondos complejos, plantas parcialmente visibles o rasgos morfológicos poco discriminantes. Este comportamiento constituye una motivación concreta para explorar, en la Entrega 3, estrategias que localicen o aíslen la región de interés antes de clasificar.

6. Análisis de los Resultados

6.1. Impacto de la complejidad arquitectónica

El hallazgo más claro de la Entrega 2 es que un modelo con mayor cantidad de parámetros no necesariamente generaliza mejor. El Experimento 1 posee 16,87 millones de parámetros y presenta un fuerte sobreajuste. El Experimento 2 reduce esa cantidad a 110,8 mil mediante GlobalAveragePooling2D y mejora simultáneamente Test Accuracy, Macro-F1 y Test Loss. La reducción aproximada del 99,34 % de parámetros se traduce en un modelo más compacto y con mejor desempeño sobre imágenes no vistas.

6.2. Generalización y sobreajuste

En el Experimento 1, las métricas de entrenamiento continúan mejorando cuando la validación deja de hacerlo, evidenciando memorización. En el Experimento 2 la evolución es más gradual y la mejor época según val_loss se encuentra al final del entrenamiento, lo que indica una generalización sustancialmente mejor. En el Experimento 3 el Data Augmentation reduce la capacidad de memorización y mantiene train y validation más cercanos, pero la mejora en regularización no se traduce en mejores métricas de test: la accuracy de especie cae de 61,12 % a 44,50 % respecto del Experimento 2.

Experimento 3 y generalización. Con Data Augmentation, el entrenamiento finalizó en la época 45 y se restauraron los pesos de la época 35, correspondiente al menor val_loss (1,5775). En esa época, train_accuracy fue 44,01 % y val_accuracy 42,92 %, mostrando una brecha mucho menor que en el Experimento 1. Sin embargo, el test alcanzó 44,50 % de accuracy y 42,56 % de Macro-F1. El resultado sugiere que las transformaciones aplicadas regularizaron el modelo, pero también introdujeron variabilidad que redujo su capacidad para aprender rasgos discriminantes en este dataset y con estos parámetros.

6.3. Heterogeneidad del dataset y clases difíciles

Las fotografías de iNaturalist no fueron tomadas bajo condiciones controladas. Dentro de una misma especie pueden observarse plantas completas, hojas, flores, frutos, ramas, distintos estados de crecimiento, fondos naturales o urbanos y condiciones variables de iluminación y escala. Esta heterogeneidad vuelve más desafiante el aprendizaje desde cero.

El análisis por clase muestra que Melia azedarach continúa siendo una de las especies más difíciles incluso después de mejorar la arquitectura. Esto sugiere que la limitación no depende únicamente de la cantidad de parámetros y requiere analizar la composición visual de esa clase, sus pares de confusión y la calidad de las fotografías.

6.4. Diferencia entre error de especie y error de condición

La arquitectura de dos etapas permite que una predicción de especie sea incorrecta y, aún así, la condición regional resulte correcta si ambas especies comparten la categoría Nativa o Exótica. Esta diferencia no constituye una inconsistencia, sino una consecuencia directa del diseño. Además, mantener el conocimiento botánico fuera de la CNN permite actualizar el catálogo sin reentrenar el modelo visual.

6.5. Interpretación de la salida Softmax

La red siempre distribuye probabilidad entre las ocho clases conocidas y selecciona una de ellas. Por lo tanto, una probabilidad Softmax elevada no garantiza que la predicción sea correcta ni que la fotografía pertenezca a una de las especies consideradas. En esta entrega se utiliza la probabilidad Softmax como indicador descriptivo y se propone el Top-3 para observar ambigüedad. La calibración o un mecanismo de rechazo por umbral quedan como posibles mejoras posteriores.

6.6. Selección del prototipo de Entrega 2

Selección final. Se selecciona el Experimento 2 como prototipo de la Entrega 2. El criterio de selección prioriza desempeño sobre datos no vistos y equilibrio entre clases, no la complejidad del modelo ni la accuracy de entrenamiento. El Experimento 3 se conserva como evidencia experimental de que Data Augmentation no garantiza una mejora automática: su efecto depende de las transformaciones, intensidad y características del problema.

7. Conclusiones

La entrega permitió construir una prueba de concepto funcional, reproducible y medible para identificar ocho especies vegetales y asociar la predicción con su condición Nativa o Exótica en la Provincia de Buenos Aires. La evaluación de tres configuraciones sobre el mismo dataset permitió no sólo medir el desempeño final, sino también analizar cómo la complejidad arquitectónica y la regularización mediante Data Augmentation afectan la capacidad de generalización.

La experimentación demuestra que la arquitectura inicial con Flatten poseía una capacidad excesiva para el volumen y la variabilidad del dataset, produciendo sobreajuste. El reemplazo por GlobalAveragePooling2D redujo los parámetros entrenables de 16.871.624 a 110.792 y elevó la accuracy de especie de 38,13 % a 61,12 %, además de mejorar el Macro-F1 de 37,55 % a 59,75 %. El Experimento 3 incorpora Data Augmentation sobre esta arquitectura y alcanzó 44,50 % de accuracy y 42,56 % de Macro-F1. Por lo tanto, el augmentation probado no produjo una mejora adicional y el Experimento 2 se selecciona como prototipo final de la Entrega 2.

Resultado del tercer experimento. El Data Augmentation llevó la accuracy de especie a 44,50 % y el Macro-F1 a 42,56 %, por debajo del Experimento 2. A nivel regional alcanzó 71,38 % de accuracy Nativa/Exótica y 71,32 % de Macro-F1. Por este motivo, el Experimento 2 queda seleccionado como versión final de la prueba de concepto, mientras que el Experimento 3 aporta evidencia sobre los límites de la regularización aplicada.

Aun con la mejora obtenida, el sistema permanece en etapa experimental. Las principales limitaciones se relacionan con la heterogeneidad visual de las imágenes, las clases con bajo

desempeño y la obligación de la salida Softmax de seleccionar una de las ocho especies conocidas.

Para una próxima evolución se propone mantener congelado el conjunto de test y comparar el prototipo seleccionado contra técnicas de mayor capacidad de transferencia y localización. En particular, Transfer Learning puede reutilizar representaciones visuales aprendidas sobre conjuntos de datos más grandes, mientras que Object Detection puede utilizarse para localizar o aislar la planta antes de la clasificación y reducir la influencia del fondo. Estas mejoras se reservan para la Entrega 3.

Código del proyecto:

https://github.com/GuidoMartinez/2026_UTN_IAA_GrupoC

Referencias

1. iNaturalist (s. f.). iNaturalist API v1 Documentation. <https://api.inaturalist.org/v1/docs/>.
2. iNaturalist (s. f.). iNaturalist Licensed Observation Images. Registry of Open Data on AWS. <https://registry.opendata.aws/inaturalist-open-data/>
3. Zuloaga, F. O. y Anton, A. M. (s. f.). Flora Argentina y Catálogo de las Plantas Vasculares del Cono Sur. Instituto de Botánica Darwinion, CONICET-ANCEFN. <https://buscador.floraargentina.edu.ar/>.
4. Ministerio de Ambiente y Desarrollo Sostenible de la Nación (s. f.). Información oficial sobre especies exóticas. <https://www.argentina.gob.ar/ambiente/biodiversidad/exoticas-invasoras/lista>.
5. PGP-MachineLearning (s. f.). demoML: ejemplos de implementaciones de algoritmos de Machine Learning en Google Colab. <https://github.com/PGP-MachineLearning/demoML>.
6. TensorFlow Developers (2025). TensorFlow 2.20.0. <https://github.com/tensorflow/tensorflow/releases/tag/v2.20.0>.