UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Inteligencia Artificial Avanzada
Grupo C
Entrega N° 3

INTEGRANTES DEL GRUPO	Correo	Aporte
Martinez, Guido Julián	guidojmartinez@frba.utn.edu.ar	16,6 %
Duarte, Gonzalo	goduarte@frba.utn.edu.ar	16,6 %
Gliozzo, Tomás Esteban	tgliozzo@frba.utn.edu.ar	16,6 %
Lazzati, Camila	clazzati@frba.utn.edu.ar	16,6 %
Ibire, Fidel	fibire@frba.utn.edu.ar	16,6 %
Ascorti, Federico	fascorti@frba.utn.edu.ar	16,6 %

Fecha de presentación
25/10/2026

Evaluación General de la Entrega

Resumen

Se presenta la evolución de un clasificador de ocho especies vegetales que, a partir de una imagen RGB, identifica la especie y consulta un catálogo para indicar su condición de nativa o exótica en la Provincia de Buenos Aires. Se compararon recortes mediante un detector preentrenado, ajustes de la tasa de aprendizaje, Transfer Learning con MobileNetV2 y fine-tuning con Data Augmentation. La línea preentrenada elevó el desempeño respecto del prototipo de Entrega 2; el fine-tuning con augmentation suave alcanzó 77,25 % de accuracy por especie en test. El informe documenta las configuraciones, la evidencia de entrenamiento y los resultados que fundamentan la elección final.

1 Introducción

El reconocimiento de especies vegetales puede apoyar la consulta de información botánica a partir de fotografías. El problema combina variaciones de iluminación, distancia, orientación, órganos visibles y fondos, que dificultan distinguir especies visualmente semejantes.

El objetivo de esta etapa es mejorar la generalización del prototipo de Entrega 2 mediante técnicas de redes convolucionales y aprendizaje por transferencia, y evaluar sus ventajas y límites con métricas globales y por especie. El sistema clasifica únicamente las ocho especies incluidas; no localiza ni identifica de forma exhaustiva todas las plantas presentes en una fotografía.

La salida regional se obtiene después de la clasificación: imagen → especie → catálogo regional → Nativa o Exótica. No se entrena un segundo clasificador binario ni se infiere invasividad. Una identificación incorrecta puede, por lo tanto, afectar también la condición informada.

2 Materiales disponibles

Las imágenes proceden de iNaturalist. Se seleccionaron observaciones de grado de investigación y una fotografía por observación, conservando identificadores, atribución, licencia y metadatos en los manifiestos. Flora Argentina y la referencia oficial nacional de especies exóticas complementan el catálogo botánico. La condición se define para Buenos Aires, aunque las imágenes no se restringen geográficamente a esa provincia.

Conjunto	Imágenes	Por especie	Proporción
Entrenamiento	1.920	240	60 %
Validación	480	60	15 %
Test	800	100	25 %
Total	3.200	400	100 %

2.1 Especies y preparación

Especie	Condición en Buenos Aires
Cortaderia selloana	Nativa
Erythrina crista-galli	Nativa
Gleditsia triacanthos	Exótica
Iris pseudacorus	Exótica
Ligustrum lucidum	Exótica
Melia azedarach	Exótica
Passiflora caerulea	Nativa
Phytolacca dioica	Nativa

Para Entrega 3 se utilizaron imágenes RGB de 224 × 224 píxeles, lotes de 32 y semilla de 42. Las imágenes preparadas se recodificaron como JPEG con calidad de 92. Los experimentos 4 y 4B aplicaron recortes cuando el detector produjo una caja aceptada; 4C y 5 a 8 utilizaron imágenes completas. El aumento de datos del 8 se aplicó solo durante entrenamiento, después del cache, sin modificar validación ni test.

2.2 Particiones y evaluación

Los experimentos 4, 4C, 5, 6, 7 y 8 comparten observaciones, fotografías, etiquetas y particiones, verificadas mediante los manifiestos. El 4B utiliza otra selección y partición y se informa como ensayo exploratorio, no como una comparación controlada de la tasa de aprendizaje. La Entrega 2 se conserva como antecedente histórico con sus resultados presentados; su comparación con esta etapa es descriptiva, sin asumir identidad de las imágenes de test.

La pérdida de validación (val_loss) determina la época recuperada y orienta la selección del modelo. Se informa accuracy Top-1, macro-F1, pérdida de test y reportes de clasificación. Accuracy mide la proporción de aciertos; precision por clase mide cuántas predicciones de esa clase son correctas; recall mide cuántos casos reales se recuperan. F1 combina precision y recall, y macro-F1 asigna el mismo peso a cada especie.

3 Solución propuesta

Se exploraron dos líneas: modificar el preprocesamiento de la CNN con GlobalAveragePooling2D y reutilizar representaciones aprendidas en ImageNet. Esta segunda línea emplea MobileNetV2 sin su clasificador original, seguida de GlobalAveragePooling2D, una capa densa de 128 unidades ReLU, Dropout de 0,30 y una salida Softmax de ocho clases.

3.1 Arquitecturas y aprendizaje

La CNN de 4, 4B y 4C normaliza a [0, 1] y utiliza tres bloques Conv2D de 32, 64 y 128 filtros de 3 × 3 con ReLU y MaxPooling2D. Se completa con GAP, Dense de 128 unidades, Dropout de 0,30 y Softmax de ocho clases; suma 110.792 parámetros.

En el Experimento 5 se congela la base MobileNetV2 y se entrena únicamente la cabeza de clasificación, con 165.000 parámetros entrenables. En 6 y 8 se habilita el ajuste desde block_16_expand, con 1.044.040 parámetros entrenables; el 7 amplía ese ajuste desde block_15_expand, con 1.359.880 parámetros. La arquitectura completa mantiene 2.422.984 parámetros y un factor de anchura de 1,0. Las capas BatchNormalization permanecen congeladas durante el fine-tuning.

El preprocesamiento de MobileNetV2 transforma los píxeles de [0, 255] a [-1, 1] dentro del modelo. Se utiliza Adam y entropía cruzada categórica. En el ajuste fino se recompila el modelo con una tasa inicial de 0,00001, menor que la utilizada para entrenar la cabeza, para adaptar los pesos preentrenados mediante actualizaciones más pequeñas.

3.2 Configuración de los experimentos

Exp.	Cambio principal	LR inicial / mínimo	Paciencia ES
4	CNN GAP con recortes de detección	0,001 / fijo	10
4B	Recortes y reducción adaptable del LR	0,001 / 0,00001	12
4C	Imagen completa y LR adaptable	0,001 / 0,00001	12
5	MobileNetV2 congelada; entrenar cabeza	0,001 / 0,00001	12
6	Fine-tuning desde block_16_expand	0,00001 / 0,0000001	12
7	Fine-tuning desde block_15_expand	0,00001 / 10^{-14}	25
8	Configuración 6 con augmentation suave	0,00001 / 0,0000001	12

Todos configuran un máximo de 200 épocas. ES corresponde a EarlyStopping sobre val_loss, con restauración de los mejores pesos. Salvo el experimento 4, en los demás se aplica ReduceLROnPlateau con factor 0,5 y paciencia de cuatro épocas. Los experimentos 6, 7 y 8 parten independientemente del mismo modelo guardado del 5, no de los pesos finales del experimento inmediatamente anterior.

3.3 Recortes y aumento de datos

Los ensayos 4 y 4B utilizan SSD MobileNet preentrenado en COCO para la categoría potted plant, con umbral 0,25 y margen de recorte del 10 %. Si no existe detección aceptada, se conserva la imagen completa. Es una exploración de preprocesamiento con un detector genérico, no el entrenamiento de un detector específico de estas especies con cajas anotadas.

El 8 incorpora reflexión horizontal y rotaciones de hasta ±10,8° (factor 0,03), con relleno reflect e interpolación bilineal. No aplica zoom ni cambios de color. Estas transformaciones varían las entradas de entrenamiento, pero no aumentan el número de observaciones independientes.

4 Desarrollo

Los cuadernos se ejecutaron en Google Colab con TensorFlow/Keras. El flujo comprende carga de manifiestos y catálogo, preparación de imágenes, construcción de los conjuntos, entrenamiento, restauración de pesos, evaluación y exportación. Se preserva el orden de las ocho clases para interpretar correctamente la salida Softmax y su correspondencia con el catálogo regional.

Para continuar desde el modelo 5 se comprueba su identidad y la partición asociada antes de entrenar. Los cuadernos exportan métricas, historiales, predicciones, reportes, matrices y figuras por corrida. Las imágenes intermedias se preparan en el almacenamiento temporal de Colab; la exportación automática del modelo .keras se mantiene deshabilitada y su guardado se realiza explícitamente cuando es necesario.

4.1 Entrenamiento de las CNN desde cero

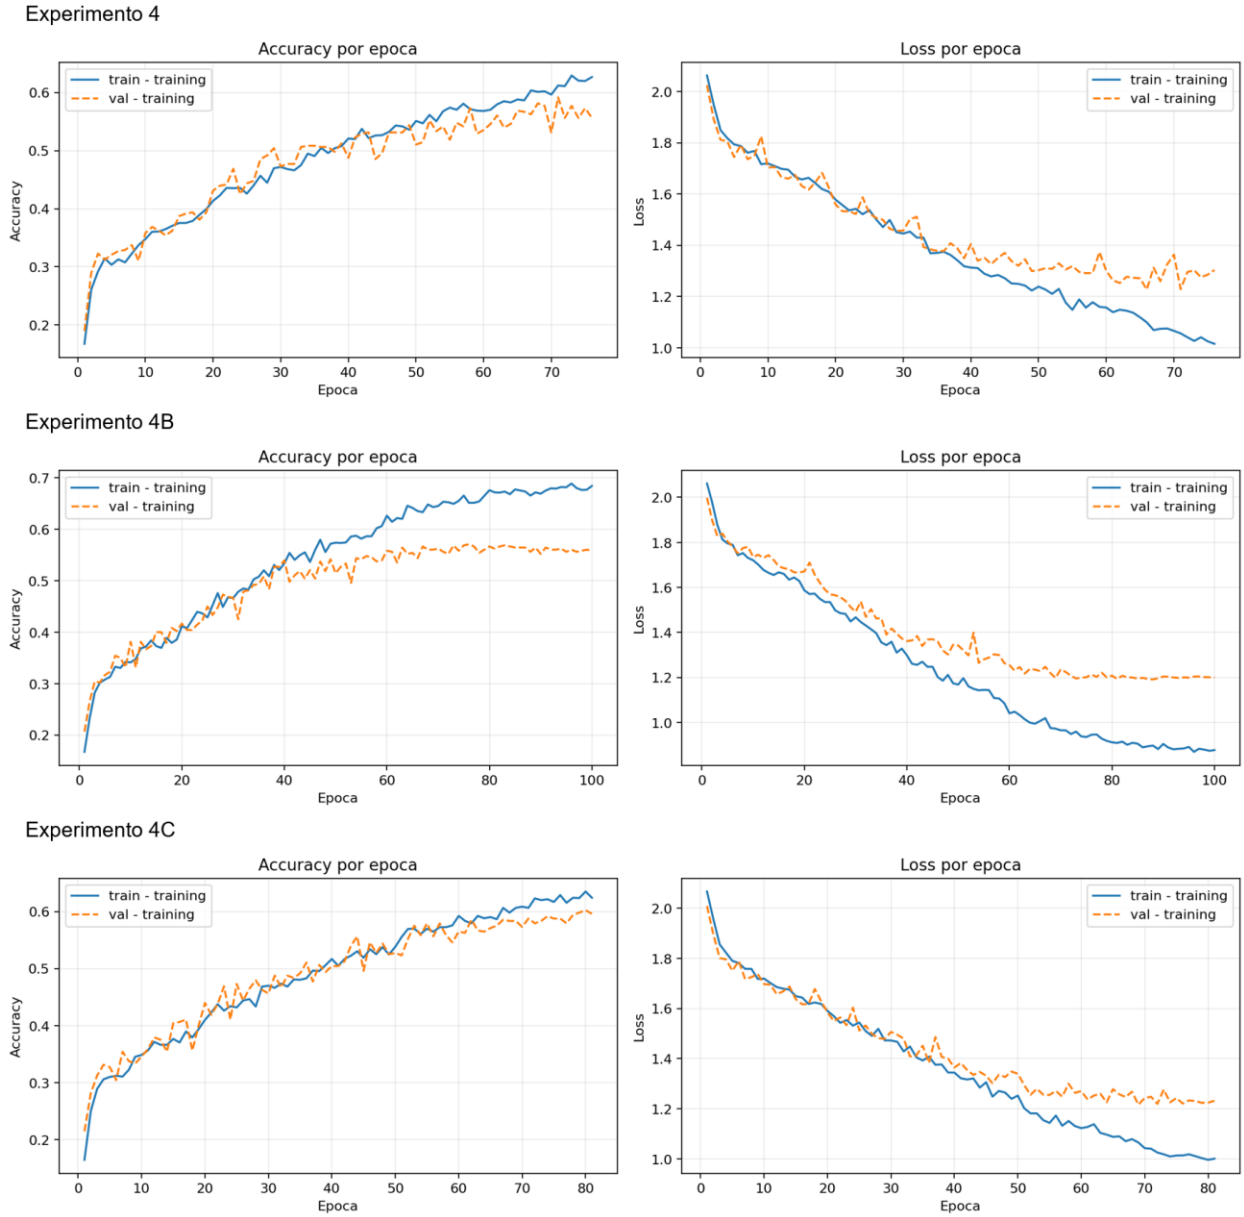


Figura 1. Accuracy y pérdida de entrenamiento (train) y validación (val) en los experimentos 4, 4B y 4C. El eje temporal es propio de cada corrida.

4.2 Transfer Learning y fine-tuning

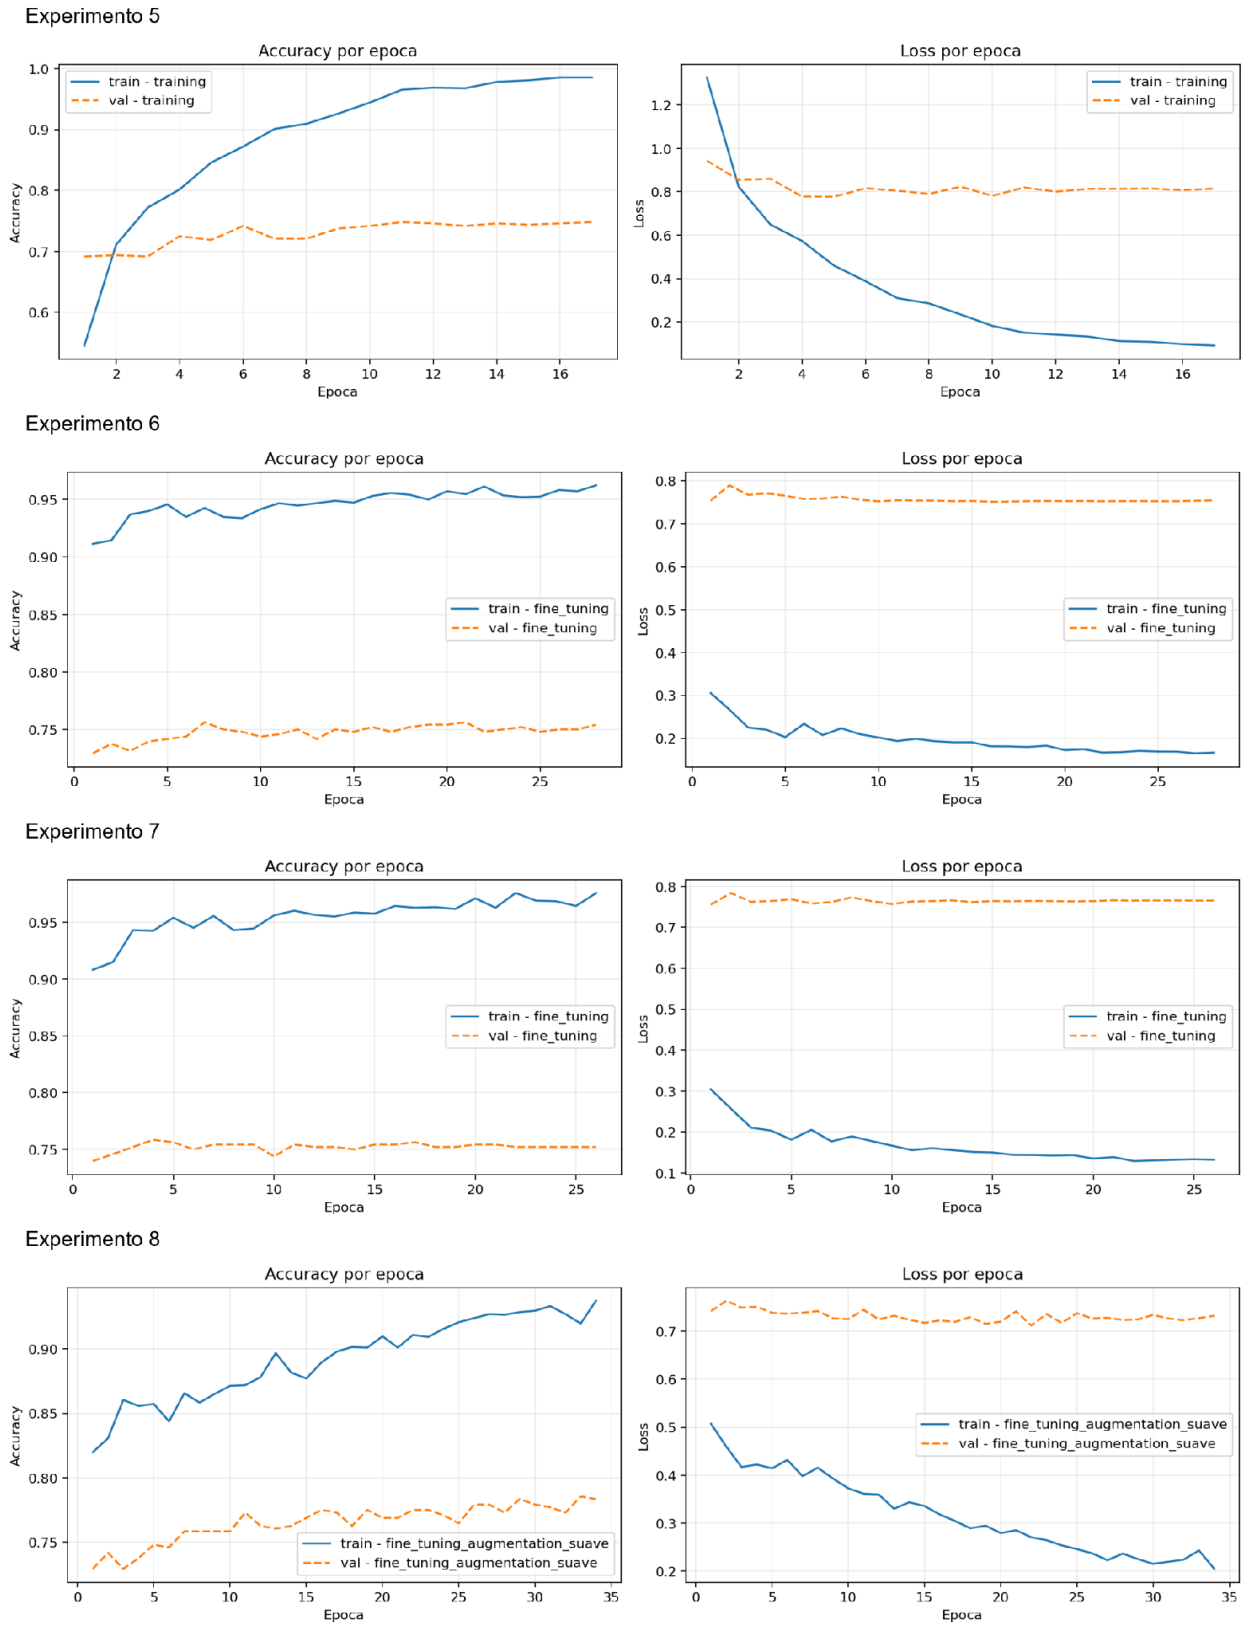


Figura 2. Entrenamiento (train) y validación (val) de los experimentos 5 a 8. Las métricas de entrenamiento del 8 incluyen augmentation; las de validación utilizan imágenes sin transformar.

Las curvas permiten distinguir el número de épocas ejecutadas del checkpoint utilizado para evaluar. En particular, el 7 completó 26 épocas y recuperó la primera: las 25 siguientes no redujeron la pérdida de validación por debajo de aquel mínimo. No se trató de una interrupción en la primera época.

5 Resultados

5.1 Comparación global en test

Cada evaluación utiliza 800 imágenes de test. Las cifras de 1 a 3 corresponden al informe presentado en Entrega 2. Se mantienen sus valores históricos; los resultados de Entrega 3 provienen de las métricas y predicciones exportadas por cada corrida.

Exp.	Acc. especie %	Macro-F1 especie %	Loss	Acc. condición %	Macro-F1 condición %
1	38,13	37,55	1,6168	70,88	70,36
2	61,12	59,75	1,1596	76,12	76,05
3	44,50	42,56	1,5409	71,38	71,32
4	57,13	56,55	1,2660	76,25	76,23
4B	57,63	57,60	1,2190	77,38	77,37
4C	57,38	56,70	1,2189	75,25	75,23
5	74,88	74,48	0,7612	84,63	84,55
6	77,38	77,34	0,7181	86,00	85,99
7	76,88	76,62	0,7077	85,75	85,73
8	77,25	77,25	0,7044	85,63	85,62

Condición corresponde a Nativa/Exótica, derivada de la especie predicha. Los experimentos 1, 2 y 3 emplean respectivamente Flatten, GAP y GAP con augmentation. El 4B se presenta con su propia partición; las diferencias con esa corrida no aíslan el efecto de un hiperparámetro. Los porcentajes se redondean a dos decimales y la pérdida a cuatro.

5.2 Épocas y validación

Exp.	Épocas ejecutadas	Época recuperada	Val loss	Val accuracy %
4	76	66	1,2271	56,67
4B	100	88	1,1913	55,62
4C	81	69	1,2162	58,33
5	17	5	0,7770	71,88
6	28	16	0,7512	75,21
7	26	1	0,7552	73,96
8	34	22	0,7122	77,50

Las métricas de validación de esta tabla corresponden al checkpoint de mínima pérdida, no al máximo de accuracy de validación alcanzado en otra época.

5.3 Reporte de clasificación por especie

Experimento 8, conjunto de test, n = 800. Precision, recall y F1 se expresan entre 0 y 1; support indica el número de imágenes reales por clase.

Especie	Precision	Recall	F1	Support
Cortaderia selloana	0,8846	0,9200	0,9020	100
Erythrina crista-galli	0,8351	0,8100	0,8223	100
Gleditsia triacanthos	0,7021	0,6600	0,6804	100
Iris pseudacorus	0,9143	0,9600	0,9366	100
Ligustrum lucidum	0,7528	0,6700	0,7090	100
Melia azedarach	0,6311	0,6500	0,6404	100
Passiflora caerulea	0,8675	0,7200	0,7869	100
Phytolacca dioica	0,6320	0,7900	0,7022	100
Macro promedio	0,7774	0,7725	0,7725	800

5.4 Evolución del F1 por especie

Especie	4	4B	4C	5	6	7	8
Cortaderia selloana	0,746	0,850	0,785	0,857	0,903	0,903	0,902
Erythrina crista-galli	0,743	0,751	0,768	0,777	0,831	0,808	0,822
Gleditsia triacanthos	0,492	0,507	0,433	0,670	0,697	0,656	0,680
Iris pseudacorus	0,724	0,802	0,779	0,886	0,935	0,931	0,937
Ligustrum lucidum	0,453	0,427	0,471	0,702	0,716	0,710	0,709
Melia azedarach	0,286	0,240	0,248	0,587	0,615	0,617	0,640
Passiflora caerulea	0,580	0,587	0,545	0,777	0,790	0,778	0,787
Phytolacca dioica	0,500	0,443	0,507	0,701	0,700	0,726	0,702

Test: 100 imágenes por especie en cada corrida. El 4B se incluye solo como referencia descriptiva. Los reportes completos de precisión, recall, F1 y support de cada experimento se conservan junto a sus resultados en el repositorio.

5.5 Matrices de confusión del Experimento 8

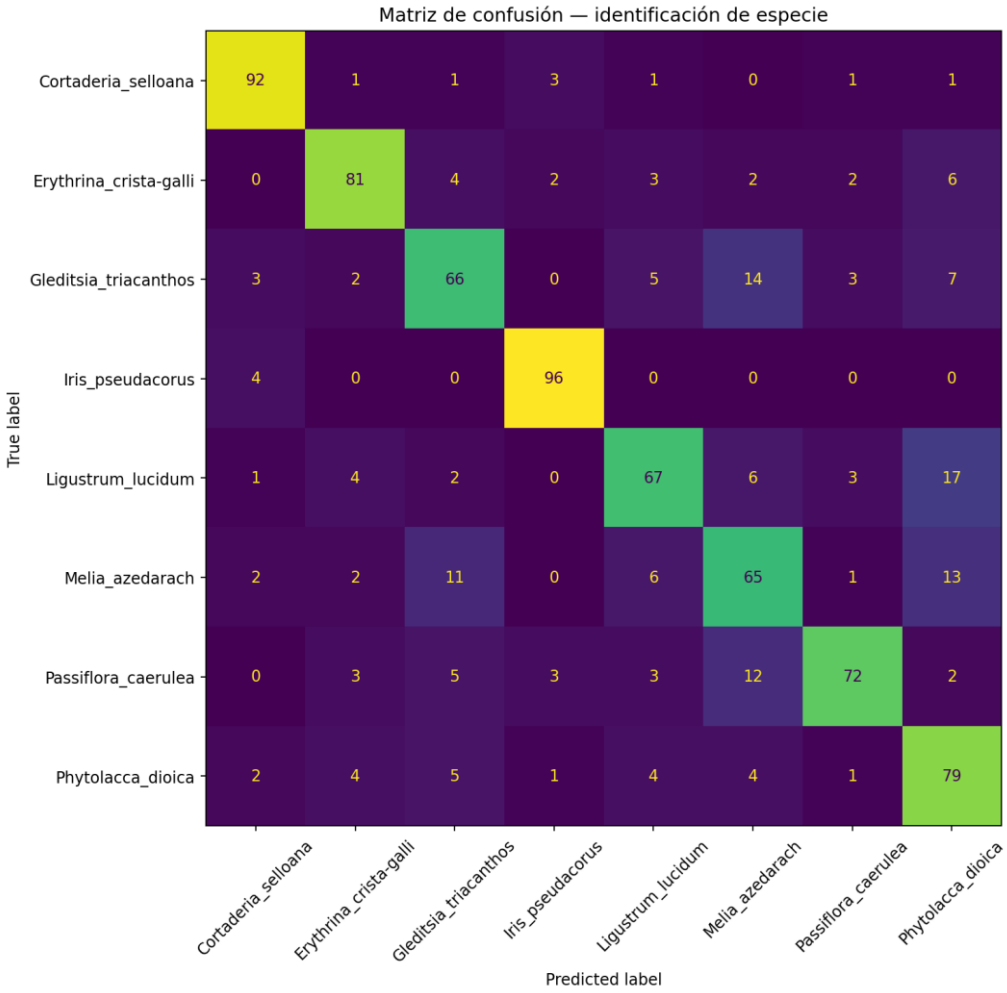


Figura 3. Matriz de confusión por especie del Experimento 8. Conjunto de prueba (test), n = 800; 100 imágenes reales por especie.

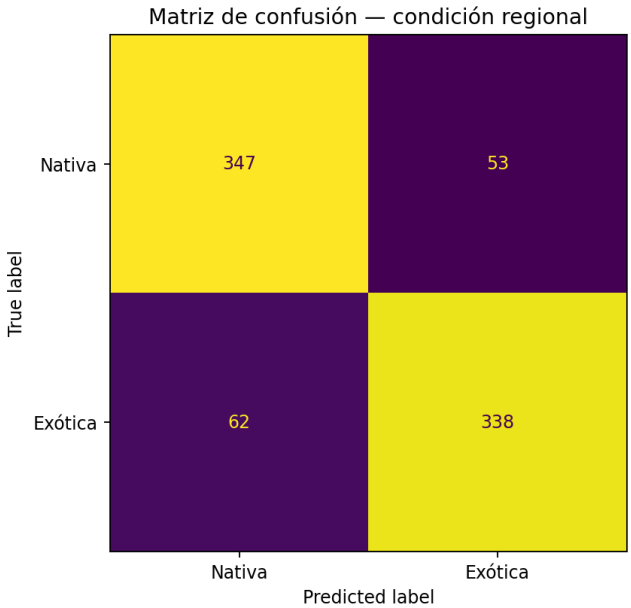


Figura 4. Matriz de confusión de Nativa/Exótica del Experimento 8. Conjunto de prueba (test), n = 800; 400 imágenes reales por condición.

5.6 Ejemplos de clasificación



Figura 5. Cuatro ejemplos de aciertos del Experimento 8 en test. Selección de los ejemplos exportados: Cortaderia, Erythrina, Melia y Passiflora. Conf. indica el puntaje Softmax, no una certeza calibrada.



Figura 6. Ejemplos de errores del Experimento 8 en test. Se muestran la clase real, la predicción y el puntaje del modelo. El puntaje Softmax no equivale a una certeza calibrada.

6 Análisis de los resultados

6.1 Recortes y ajustes de la CNN

El Experimento 2 fue el prototipo seleccionado de Entrega 2. La CNN con Flatten presentó menor generalización y el aumento de datos del experimento 3 no mejoró esa base. Estos antecedentes no permiten atribuir todo el cambio a una sola técnica, también variaron la resolución o el presupuesto de entrenamiento y la paciencia.

En el experimento 4, se recortaron 1.136 de 3.200 imágenes (35,50 %). Esta proporción describe el uso del recorte, no la exactitud del detector. El desempeño no mostró una ventaja clara sobre el 4C, que conservó las imágenes completas. Como 4C también incorpora LR adaptable, la comparación no constituye una ablación exclusiva del recorte. El 4B tampoco permite aislar ese efecto por utilizar otra partición. Se cerró esta línea sin afirmar que Object Detection sea ineficaz en general: el detector genérico y la ausencia de cajas botánicas de referencia limitan la interpretación.

6.2 Transferencia y profundidad del fine-tuning

El experimento 5 supera al 4C en 17,50 puntos porcentuales de accuracy de test sobre la misma partición. El resultado respalda la configuración preentrenada, aunque también cambian la arquitectura y el preprocesamiento. El experimento 6 agrega fine-tuning y obtiene 20 aciertos más que el 5, con menor pérdida de validación. Adaptar una parte de la base fue más efectivo que entrenar únicamente la cabeza.

El experimento 7 habilita un bloque adicional y eleva la paciencia a 25. Aumenta la accuracy de entrenamiento, pero no mejora el mínimo de val_loss del 6. Su menor test loss convive con cuatro aciertos menos: la pérdida considera las probabilidades asignadas, mientras accuracy solo considera la clase ganadora. El piso del LR se redujo a 10^{-14}, pero el mínimo observado fue $1{,}5625 \times 10^{-7}$; ese nuevo límite no llegó a activarse. Una mayor capacidad entrenable y más épocas no aseguraron mejor generalización.

6.3 Augmentation suave y errores restantes

El experimento 8 conserva el punto de partida y la configuración de fine-tuning del 6 y agrega transformaciones suaves. Mejora la accuracy de validación en 11 imágenes sobre 480 y reduce val_loss. En test obtiene un acierto menos que el 6 (618 frente a 619), con menor pérdida. No hay contradicción ni evidencia de superioridad en todas las métricas. La diferencia con el resultado del 3 muestra que el efecto del augmentation depende de su intensidad, de la arquitectura y del entrenamiento.

Iris pseudacorus presenta el F1 más alto del 8 (0,9366), y Melia azedarach el menor (0,6404). Destacan las confusiones Ligustrum → Phytolacca (17), Gleditsia → Melia (14) y Melia → Phytolacca (13). Los ejemplos son compatibles con variaciones de órganos visibles y contexto visual, pero no demuestran por sí solos qué región utiliza la red. La salida regional conserva 67 casos con especie incorrecta pero condición correcta; su accuracy mayor no reemplaza la evaluación por especie.

6.4 Alcance de las comparaciones

Los resultados corresponden a una corrida por configuración. El conjunto de test fue consultado durante el desarrollo, por lo que no representa una evaluación externa nunca observada. No se afirma significancia estadística ni se garantiza el mismo desempeño en nuevas fotografías. La comparación con el ensayo 4B es descriptiva al considerar otra partición: las comparaciones dentro de la partición común son más directas, pero los cambios simultáneos deben considerarse al interpretar las causas.

7 Conclusiones

Se selecciona el Experimento 8 como prototipo final de Entrega 3: MobileNetV2 con fine-tuning desde block_16_expand, BatchNormalization congelada y augmentation suave, utilizando los pesos recuperados de la época 22. La elección se fundamenta en la menor pérdida de validación entre las variantes evaluadas, y no en maximizar retrospectivamente la accuracy de test. El experimento 6 conserva un acierto adicional en test, aunque esa diferencia no altera el criterio adoptado.

Respecto del prototipo presentado en Entrega 2, la evolución eleva la accuracy por especie de 61,12 % a 77,25 % y mejora macro-F1. El principal avance provino de reutilizar representaciones preentrenadas y adaptarlas parcialmente al problema. Los recortes del detector ensayado no aportaron una mejora concluyente y no forman parte del prototipo final.

7.1 Lecciones aprendidas

La identidad de los datos, las particiones y el orden de clases son condiciones necesarias para continuar un entrenamiento y comparar resultados. La restauración por validación evita confundir la última época con la más conveniente. Aumentar parámetros o paciencia no asegura generalización; accuracy, F1 y pérdida ofrecen perspectivas complementarias. Data augmentation debe adecuarse al problema y no evaluarse como una técnica universalmente beneficiosa o perjudicial.

7.2 Alcance y continuidad

No se incorporó segmentación porque el dataset no dispone de máscaras de referencia. Su aplicación requeriría anotarlas o revisar las generadas por un modelo preentrenado para comprobar que preservan las estructuras botánicas relevantes. Ese trabajo manual queda fuera del alcance de esta entrega. La técnica se mantiene como línea futura, sin concluir que carezca de utilidad.

Una siguiente evaluación debería utilizar fotografías nuevas y repetir configuraciones con distintas semillas. Para una interfaz de consulta, pueden mostrarse las tres especies de mayor puntaje como ayuda al usuario, sin confundir esa presentación con una mejora medida de accuracy Top-1 ni con una identificación garantizada. El uso se limita a las ocho clases estudiadas.

Referencias y material complementario

El repositorio reúne el informe anterior, los cuadernos de esta etapa y los resultados por experimento. Cada carpeta de resultados incluye métricas, reportes de clasificación, curvas, matrices y ejemplos; las tablas y figuras de este informe sintetizan esa evidencia.

Repositorio del trabajo: https://github.com/GuidoMartinez/2026_UTN_IAA_GrupoC

Exp.	Carpeta dentro de Entrega_3/resultados
4	04_ObjectDetection_CNN_GAP
4B	04B_ObjectDetection_CNN_GAP_LR
4C	04C_CNN_GAP_SinRecorte_LR
5	05_TransferLearning_MobileNetV2
6	06_Exp6_FineTuning_MobileNetV2
7	07_Exp7_FineTuning_MobileNetV2_block15
8	08_Exp8_FineTuning_MobileNetV2_AugmentationSuave

Los cuadernos 6, 7 y 8 requieren el modelo .keras del Experimento 5, sus métricas y su manifiesto de particiones. El modelo 5, sus métricas y su manifiesto están incluidos en la carpeta Entrega_3/resultados/05_TransferLearning_MobileNetV2 del repositorio. Los resultados exportados no sustituyen los pesos del modelo final; para inferencia inmediata con la corrida del 8 es necesario conservar su archivo de modelo.

- iNaturalist. Documentación de la API y observaciones. https://api.inaturalist.org/v1/docs/
- Flora Argentina. Catálogo y buscador botánico. https://buscador.floraargentina.edu.ar/
- Argentina. Lista oficial de especies exóticas. https://www.argentina.gob.ar/ambiente/biodiversidad/exoticas-invasoras/lista
- Sandler, M., Howard, A., Zhu, M., Zhmoginov, A. y Chen, L.-C. (2018). MobileNetV2: Inverted Residuals and Linear Bottlenecks. https://arxiv.org/abs/1801.04381
- Keras. Transfer learning and fine-tuning. https://keras.io/guides/transfer_learning/